데이터마이닝이론 S T A 6 6 0 0 김현중 교수님

Homework 1

2018314030

응용통계학과 김단아

- 1. Write programs to implement the multiple linear regression analysis. Do not use an R command such as 'lm' or 'glm'.
 - a. Make the program to accept file names for data and output from the user. Give the user a prompt to type-in the data file and output file names. (Hint: use 'readline' command in R)

```
# import data file
  data = readline("Enter the data file name (with extension name) : " )
  cat("Select the data coding format(1 = 'a b c' or 2 = 'a,b,c'): ")
  fm = scan(n=1, quiet=TRUE)
  if(fm==1) {form = ""} else {form = ","}
  data = read.table(data, sep=form)

# make output file
  outputname = readline("Write the output file name you want to save (without extension name): ")
  outputname = paste(outputname,".txt",sep="")
```

- 위 R 코드는 multiple linear regression analysis 를 수행하는 함수의 일부이다. 불러들일 data file과 저장할 file names을 유저가 직접 치는 프롬프트 창을 이용하는 코드이다. Assignment의 예시를 사용하였다.

b. The program must print out the coefficient for each X variable and save it into an output file.

```
# design matrix

n = dim(data)[1]

p = dim(data)[2]-1

one = matrix(1, nrow=n, ncol=1)

I = diag(n)

y = as.matrix(data[,1])

x = as.matrix(cbind(one,data[,-1]))

H = x%*%solve(t(x)%*%x)%*%t(x)

H0 = one%*%solve(t(one)%*%one)%*%t(one)
```

```
# multiple regression result
b = round(solve(t(x))%*%x)%*%t(x)%*%y, 4)
yhat = x%*%b
SST = t(y)%*%(I-H0)%*%y
SSE = t(y)%*%(I-H)%*%y
Rsquare = round(1 - SSE/SST, 4)
MSE = round(SSE/(n-p), 4)

# output - coefficient
name = paste("Beta",c(0:p),":",sep="")
name[1] = "Constant:"
row.names(b) = name

# make output file
    cat("Coefficients","\m'n","--------","\m'n",file = outputname,sep="")
    write.table(b, outputname, sep= " ", row.names=TRUE, col.names=FALSE, append=TRUE,
quote=FALSE)
```

- H 매트릭스를 사용하여 다중회귀분석을 수행한 후, 그 추정계수를 b를 output 파일에 저장하는 코드의 일부이다.
- c. The program must calculate the fitted values and save it into an output file.

```
# multiple regression result
   yhat = x%*%b

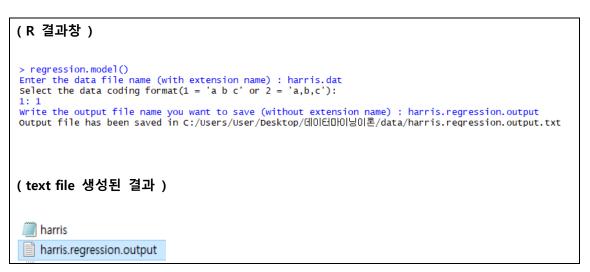
# output - ID, Actual values, Fitted values
   y.values = cbind(c(1:n), y, round(yhat,1))

# make output file
cat("\text{\pin}","ID, Actual values, Fitted values","\text{\pin}","------","\text{\pin}",
   file = outputname,sep="", append=TRUE)
   write.table(y.values, outputname, sep= ", ", row.names=FALSE, col.names=FALSE,
   append=TRUE, quote=FALSE)
```

- 매트릭스를 이용하여 구한 fiited value(yhat)에 ID와 Actual value를 추가하여 output 파일에 저장하는 코드의 일부이다.

f. Use a data file named "harris.dat" for this assignment. Assume that the first one is the response variable.

```
regression.model()
harris.dat
1
harris.regression.output
```



- 첫번째 열을 반응변수로 가정하고 "harris.dat"을 regression.model 함수를 이용하여 회귀분석을 진행한 결과이다. output으로 지정해준 파일 이름 그대로 "harris.regression.output.txt"가 생성됨을 확인할 수 있다.
- g. The output file generated by the program must look like the below (the sample output is not the true one).

```
( harris.regression.output.txt )
Coefficients
Constant: 3526.4221
Beta1: 90.0203
Beta2: 1.269
Beta3: 23.4062
Beta4: 722.4607
ID, Actual values, Fitted values
_____
1, 3900, 4630.1
2, 4020, 4646.3
3, 4290, 5315.2
4, 4380, 4418.3
.....(생략).....
90, 6840, 5815.7
91, 6900, 5785.3
92, 6900, 6328.4
93, 8100, 6530.8
Model Summary
-----
R-square = 0.5109
MSE = 254583.5835
```

- 위의 두 포맷이 동일하고 lm 함수로 구한 결과가 동일함을 확인할 수 있다.